NLP 作业一：文本分类实验报告

一、实验背景与目的

本次作业旨在帮助大家理解和掌握不同文本表示方法在文本分类任务中的基本原理与实际效果。你将分别使用传统词袋模型、Word Embedding / Word2Vec，以及预训练语言模型对文本进行表示，并训练文本分类模型。

1. 理解不同文本表示方法的基本思想；
2. 掌握文本分类任务的基本实验流程；
3. 熟悉 Logistic Regression 在文本分类中的使用；
4. 掌握 Word2Vec、GloVe 等词向量的基本使用方法；
5. 熟悉 BERT 类预训练语言模型的 Fine-tuning 流程；
6. 能够使用 Accuracy 和 Macro-F1 对文本分类模型进行评价；
7. 能够对不同文本表示方法的性能进行基本比较和分析。

二、数据集与实验设置

（一）数据集介绍

1. New York Times (NYT) 新闻数据集

NYT 数据集包含以下两列：

text：新闻文本

label：新闻所属类别

NYT 数据集将作为本次作业的主要文本分类数据集。

2. AG News 数据集

AG News 数据集提供新闻文本（text）。在本次作业中，AG News 主要用于训练 Word2Vec 词向量。

（二）数据划分

为保证不同方法之间具有可比性，所有实验统一使用相同的数据划分。首先对 NYT 数据集进行随机打乱，然后按 Training：Validation：Test = 80%：10%：10%的比例进行分层抽样，确保三个类别在三个子集中的比例一致。随机种子统一设置为 `random_state=42`，以保证实验可复现。具体划分结果为：训练集 9215 条，验证集 1152 条，测试集 1152 条。

（三）评价指标

1. Accuracy：即分类正确的样本数量占全部测试样本数量的比例。

2. Macro-F1：分别计算每一个类别的 F1 Score，然后对所有类别的 F1 进行平均。对于类别分布可能不均衡的文本分类任务，Macro-F1 可以更加全面地反映模型在不同类别上的分类能力。

（四）实验环境

实验使用 Python 3.10，主要依赖库包括：`scikit-learn`（用于 CountVectorizer 和 Logistic Regression）、`gensim`（用于 Word2Vec 训练）、`transformers`（用于 BERT 微调）、`torch`（深度学习框架）、`numpy`、`pandas`（数据处理）。BERT 微调在有 NVIDIA GPU 的环境下运行。

三、Task 1：Bag of Words

（一）方法原理

词袋模型是文本表示中最经典的方法。其核心思想是把一篇文档看作一个"词的集合"，忽略词序、句法和上下文，只关注词是否出现以及出现多少次。首先在训练语料上构建词表，假设词表大小为 |V|，则每篇文档被表示为一个 |V| 维向量，每一维对应词表中的一个词。

词袋模型的优点是简单、高效、可解释：构建过程无需训练，计算速度快；每个维度对应一个具体的词，模型学到的权重可以直接解读为"这个词对某个类别的重要性"。其缺点是丢失了词序和语义信息，无法处理同义词和多义词。

Binary Bag of Words

Binary Bag of Words 是词袋模型最基础的变体。对于词表中的第 i 个词，若该词出现在文档中，则向量第 i 维取值为 1，否则取值为 0。该方法完全忽略词的出现次数。

这种表示的合理性在于：在很多文本分类任务中，某个关键词是否出现比它出现了多少次更具判别力。Binary BoW 通过二值化起到降噪和归一化作用，避免长文档因词数多而主导权重。

（三） Word Frequency Bag of Words

Word Frequency 是 Binary BoW 的扩展。对于词表中的第 i 个词，若该词在文

档中出现了 c_i 次，则向量第 i 维取值为 c_i。该方法保留了词频信息，其合理性在于：词的重复出现确实是重要的信号，可以帮助模型区分"偶然提及"和"重点讨论"。

但词频表示也带来问题：长文档天然具有更高的词频总和，可能占据过大权重；极高频但判别力低的词可能干扰模型。

（四）实验结果

方法	Test Accuracy	Test Macro-F1
Binary Bag of Words	0.9902	0.9761
Word Frequency	0.9893	0.9739

（五） 结果分析

两种词袋模型均取得接近 0.99 的准确率，是所有六种方法中表现最好的两个。Binary BoW（0.9902/0.9761）略高于 Word Frequency（0.9893/0.9739），两者准确率仅差 0.0009，宏 F1 仅差 0.0022，差距在统计上不显著。

这一结果说明：在 NYT 这个任务上，"词是否出现"已经提供了足够的信息，词频的额外贡献非常有限。

四、Task 2：Word Embedding

（一）方法原理

词向量方法的核心思想是把每个词映射到一个低维稠密的实数向量空间中，使得语义相似的词在向量空间中距离相近。与词袋模型中每个词独立成维、词与词之间毫无关联不同，词向量通过分布式表示让词与词之间产生语义联系。

词向量的训练基于分布式假设：一个词的含义由它经常出现的上下文决定。Word2Vec 通过 Skip-gram 或 CBOW 架构在大规模语料上学习词向量；GloVe 通过全局词共现矩阵的分解来学习词向量。两者都生成静态词向量——同一个词无论在什么上下文中出现，都用同一个向量表示。

在文档分类任务中，词向量不能直接使用，因为文档包含多个词而分类器需要固定维度输入。本实验采用平均池化策略：对文档中所有有效词的词向量取算术平均，得到一个 100 维文档向量，再送入 Logistic Regression 分类。三组实验统一使用 100 维词向量。

（二）Pre-trained GloVe

GloVe 结合了全局矩阵分解和局部上下文窗口两种思想：先统计整个语料库的词共现矩阵，再通过加权最小二乘回归学习词向量，使得词向量的点积尽可能逼近词共现概率的对数。本实验使用 glove.6B.100d.txt，即在 60 亿 token 的 Wikipedia + Gigaword 语料上训练的 100 维词向量，词表规模约 40 万。

使用预训练 GloVe 的优势在于：语料规模大、覆盖广、语义稳定，几乎任何常见英文单词都能找到对应向量。缺点在于它是通用领域词向量，不针对新闻领域优化；且作为静态词向量，无法处理多义词。

（三） Word2Vec Trained on AG News

Word2Vec 是 Google 提出的词向量训练方法，包含 CBOW 和 Skip-gram 两种架构。本实验使用 Skip-gram 架构：给定中心词，预测其上下文词。相比 CBOW，Skip-gram 对低频词的处理更好，适合语料规模不大的场景。

本实验在 AG News 的全文文本上训练 100 维 Word2Vec，参数设置为：vector_size=100, window=5, min_count=1, sg=1, epochs=5。训练完成后，用得到的词向量对 NYT 文档进行平均池化表示，再训练 Logistic Regression。

AG News 训练的 Word2Vec 的问题在于领域不匹配：AG News 是四类新闻，NYT 是三类新闻，类别体系不同。尤其是 NYT 的 politics 类在 AG News 中没有直接对应，导致 politics 相关词汇在 AG 语料中出现频率低，训练出的词向量质量差。

（四） Word2Vec Trained on NYT

为了验证领域匹配的重要性，本实验进一步在 NYT 训练集上训练 Word2Vec，参数与 AG News 版本完全相同。NYT 训练的 Word2Vec 的优势在于领域完全匹配：训练语料就是 NYT 新闻。词向量的语义空间和下游分类任务高度一致，三类关键词都能得到充分训练。劣势在于语料规模小，部分低频词无法得到充分训练。

（五）实验结果

方法	Test Accuracy	Test Macro-F1
GloVe 6B 100d	0.9841	0.9621
Word2Vec trained on AG News	0.9780	0.9479
Word2Vec trained on NYT train	0.9815	0.9529

（六）结果分析

三种词向量方法的排序为：GloVe 100d（0.9841/0.9621）> Word2Vec (NYT)（0.9815/0.9529）> Word2Vec (AG)（0.9780/0.9479）。这个排序不是偶然的，而是由"词向量质量"和"领域匹配度"两个因素共同决定的。

GloVe 表现最好，是因为它在大规模通用语料上训练，词表高达 40 万，覆盖了几乎所有常见英文单词。无论 NYT 新闻里出现什么词，几乎都能在 GloVe 词表中找到对应向量，且向量质量可靠。这体现了大规模预训练语料的覆盖优势。

Word2Vec (NYT) 优于 Word2Vec (AG)，则体现了领域匹配的重要性。虽然 NYT 训练集只有 9,215 条，远小于 AG News 的 12 万条，但它的领域与下游任务完全一致，词向量语义空间与分类任务高度对齐。尤其是 politics 类关键词，在 NYT 语料中得到了充分训练，而在 AG News 中则严重不足。这说明一个在相关领域小语料上训练的词向量，可能比一个在无关领域大语料上训练的词向量更有用。

Word2Vec (AG) 最弱，正是领域不匹配的直接后果。AG News 没有 politics 类，导致 politics 相关词汇训练不足，词向量质量差，最终拖累了整体性能。

从 Acc-F1 差距来看，三种词向量方法分别为：GloVe 0.0220、Word2Vec (NYT) 0.0286、Word2Vec (AG) 0.0301，都明显高于词袋模型（~0.015）。这说明词向量方法存在更严重的多数类偏向。原因在于平均池化后的文档向量是稠密的、语义平滑的，模型难以从中提取决定性特征，Logistic Regression 会更倾向于依赖"整体语义倾向"而非"关键判别特征"，从而更容易偏向样本量大的类别。

平均池化是词向量方法的共同瓶颈。它严重丢失词序和句法信息：not good 和 good not 平均后完全相同；主谓宾关系被抹平；多义词只能用同一向量表示；长文档中关键信息被大量中性词稀释。这些问题共同导致词向量方法的性能天花板低于 BoW。

五、Task 3：Pre-trained Neural Models

（一）方法原理

预训练语言模型代表了文本表示技术的最新范式。BERT（Bidirectional Encoder Representations from Transformers）通过大规模预训练 + 下游任务微调的方式，学习上下文相关的动态词表示：同一个词在不同句子中会有不同的向量表示，从而解决了静态词向量无法处理多义词的根本局限。

BERT 的核心架构是 Transformer Encoder，通过多头自注意力机制捕捉句子中任意两个词之间的依赖关系，通过双向编码同时利用左右上下文信息。BERT 的预训练包含两个任务：掩码语言模型（随机遮盖 15% 的词并预测）和下一句预测（判断两个句子是否连续）。预训练完成后，BERT 学习到了丰富的语言知识，可以通过微调快速适配下游任务。

在文本分类任务中，BERT 的使用方式是：在输入文本前加上特殊的 [CLS] token，将文本送入 BERT 编码，取最后一层 [CLS] 位置的输出向量作为整句的语义表示，再通过一个线性分类层输出类别概率。微调时，BERT 的全部参数和分类层一起更新。

（二）实验配置

本实验使用 google-bert/bert-base-uncased 模型，这是 BERT 的 base 版本，包含 12 层 Transformer、768 维隐藏层、12 个注意力头、1.1 亿参数。uncased 表示所有文本先转为小写再处理。

训练配置为：最大序列长度 64，训练轮数 3，学习率 2e-5，训练批次大小 16，评估批次大小 32,随机种子 42,每个 epoch 评估和保存一次检查点,warmup 比例 0.1，权重衰减 0.01。使用 Hugging Face Transformers 的 Trainer 完成训练，根据验证集 Macro-F1 选择最佳检查点。

BERT 微调的关键挑战在于序列长度限制。BERT 的最大输入长度是 512，但本实验设置为 64，意味着只保留每篇新闻的前 64 个 token。NYT 新闻通常几百词，截断到 64 个 token 相当于只看到标题和开头一两句话，信息损失严重。这是 BERT 在本次任务上未能取得绝对优势的重要原因之一。

另一个挑战是数据量偏小。NYT 训练集约 9,215 条，对 1.1 亿参数的 BERT 来说偏少，容易欠拟合或过拟合。

（三）实验结果

方法	Test Accuracy	Test Macro-F1
BERT-base-uncased	0.9832	0.9644

（四）结果分析

BERT 取得 0.9832 的准确率和 0.9644 的宏 F1。虽然 Accuracy 略低于 BoW（0.9902）和 GloVe（0.9841），但 Macro-F1 0.9644 是三种词向量类方法中

最高的（GloVe 0.9621，Word2Vec 0.9529/0.9479）。同时，BERT 的 Acc-F1 差距仅 0.0188，是六种方法中第二小的（仅次 Binary BoW 的 0.0141），远小于三种词向量方法（0.0220~0.0301）。

这两个事实共同说明：BERT 在类别均衡性上表现最好，它对小类别的判断最公平。这一现象完全符合 BERT 的设计原理：BERT 通过大规模预训练学习了深层语义表示，它的 [CLS] 向量编码的是整句的语义，而不是关键词的简单叠加。在微调过程中，BERT 会根据分类任务调整注意力权重，自动学习"哪些语义特征对区分类别重要"，而不是机械地依赖关键词出现与否。因此，即使某个小类别的样本较少，BERT 也能通过语义泛化做出相对准确的判断，不容易被多数类"带偏"。这正是预训练语言模型相对于词袋和静态词向量的核心价值所在。

BERT 为什么没有在 Accuracy 上超过 BoW？原因有四。第一，任务太简单，BoW 已接近上限：NYT 三分类的关键词区分度极高，BoW 已达 0.99 准确率，剩余错误空间只有 1%，BERT 再强也难以在小空间里提升，这是典型的"天花板效应"。第二，max_length=64 导致长新闻被严重截断：BERT 看到的文本信息量远小于 BoW（BoW 用了全文所有词），信息量的差异直接抵消了 BERT 的语义优势。第三，训练数据量偏小：9,215 条样本对 1.1 亿参数的 BERT 偏少，容易欠拟合或过拟合。第四，3 epochs 可能未完全收敛：在数据量小的情况下，3 epochs 是一个合理但偏保守的设置。

六、结果汇总与对比

（一）全部方法测试集结果

方法	Test Accuracy	Test Macro-F1
Binary Bag of Words	0.9902	0.9761
Word Frequency	0.9893	0.9739
GloVe 6B 100d	0.9841	0.9621
Word2Vec trained on AG News	0.9780	0.9479
Word2Vec trained on NYT train	0.9815	0.9529
BERT-base-uncased	0.9832	0.9644

（二）Accuracy 与 Macro-F1 差距分析

方法	Accuracy	Macro-F1	差距
Binary BoW	0.9902	0.9761	0.0141
Word Frequency	0.9893	0.9739	0.0154
BERT	0.9832	0.9644	0.0188
GloVe	0.9841	0.9621	0.0220
Word2Vec (NYT)	0.9815	0.9529	0.0286
Word2Vec (AG)	0.9780	0.9479	0.0301

从 Acc-F1 差距可以总结出三条规律：

1. 表示越稀疏、越接近原始词特征，Acc-F1 差距越小。BoW 是最稀疏的表示，每个词独立成维，模型可以精确地为每个类别的关键词赋权，不存在语义平滑导致的偏向，所以差距最小（~0.015）。BERT 虽然稠密，但有注意力机制，可以为不同位置分配不同权重，所以差距也较小（0.0188）。词向量平均是最平滑的表示，所有词被压缩成一个向量，类别特征被稀释，所以差距最大（~0.03）。

2. Acc-F1 差距与领域匹配度负相关。Word2Vec (AG) 差距最大（0.0301），正是因为它领域不匹配；GloVe 差距次之（0.0220），因为它是通用语料而非新闻领域；Word2Vec (NYT) 差距居中（0.0286），虽然领域匹配但语料小。这说明领域不匹配会加剧多数类偏向：当词向量无法准确表示小类别特征时，模型只能依赖多数类的通用特征，导致小类别 F1 下降。

3. Macro-F1 比 Accuracy 更能揭示模型的真实能力。如果只看 Accuracy，GloVe（0.9841）看起来比 BERT（0.9832）好；但看 Macro-F1，BERT（0.9644）明显优于 GloVe（0.9621）。如果小类别在实际应用中很重要，那么 BERT 才是更好的选择。这个例子很好地说明了为什么在类别可能不均衡的文本分类任务中，Macro-F1 是比 Accuracy 更可靠的评价指标。

八、总结

综合来看，本次实验在 NYT 三分类任务上系统比较了六种文本表示方法，得到以下核心结论。

第一，词袋模型在这个任务上最强。 Binary BoW 取得最佳 Accuracy（0.9902）和最佳 Macro-F1（0.9761），Word Frequency BoW 紧随其后（0.9893/0.9739），两者差异不显著。这说明 NYT 新闻分类本质上是关键词驱动的任务，简单方法配合线性分类器已接近性能上限。

第二，词向量方法中领域匹配至关重要。 GloVe 凭借大规模通用语料取得最好性能（0.9841/0.9621），Word2Vec (NYT) 凭借领域匹配位居第二（0.9815/0.9529），Word2Vec (AG) 因领域不匹配最弱（0.9780/0.9479）。三者都受限于平均池化导致的信息损失，Acc-F1 差距明显大于 BoW。

第三，BERT 在类别均衡性上表现最好。 虽然 Accuracy（0.9832）未超过 BoW，但 Macro-F1（0.9644）是词向量类方法中最高的，Acc-F1 差距（0.0188）也是最小的之一。这说明预训练语义表示对小类别更公平，不依赖"猜多数类"拉高 Accuracy。BERT 未取得绝对优势的原因在于任务简单、max_length=64 截断、数据量偏小。

第四，方法选择必须匹配任务特性。在关键词区分度高、数据量小、序列较短的任务上，BoW 是性价比最高的选择；在需要语义理解、数据量充足、序列较长的任务上，BERT 才是更优选择。没有绝对最好的方法，只有最适合当前任务的方法。